


Simulering av smittspridning med hjälp av matematik och programmering

Komvuxarbete Naturvetenskap / Teknik

2026



Isak Skoog

Komvux Alingsås / Hermods

Abstract

This study investigates how mathematical models and programming can be used to simulate and analyze the spread of infectious diseases. The work focuses on the SIR model and an agent-based model (ABM), both implemented in Python. By varying parameters such as transmission rate and recovery rate, the simulations demonstrate how small changes can significantly affect the development of an epidemic.

The results show that the transmission rate is the most critical factor influencing the peak and speed of infection. The deterministic SIR model provides a clear overview of general trends, while the agent-based model reveals the importance of spatial distribution and randomness. The study also highlights how reduced mobility and contact rates can limit the spread of disease.

The conclusion is that programming serves as a powerful tool for transforming mathematical theory into visual and experimental simulations. This makes it possible to better understand complex systems such as epidemics and to evaluate different intervention strategies.

Innehållsförteckning

1. Inledning.....	5
1.1. Inledning.....	5
1.2. Syfte och avgränsningar.....	5
1.3. Frågeställningar.....	5
1.4. Metod och material.....	6
1.4.1. Simuleringsdesign.....	6
1.4.2. Parametervariation.....	6
1.4.3. Upprepade simuleringar (stokastisk modell).....	6
1.4.4. Datainsamling.....	6
1.4.5. Analysmetod.....	7
1.4.6. Begränsningar.....	7
1.5. Arbetsplan.....	7
2. Bakgrund.....	8
2.1. Historisk utveckling av kunskap och smittspridning.....	8
2.2. Datorbaserade simuleringar inom epidemiologi.....	9
2.3. Visualisering och programmering.....	9
3. Undersökning.....	10
3.1. Matematiska grunder: SIR-modellen.....	10
3.2. Implementation av två modeller och parameteranalys.....	11
3.2.1. Matematisk modell och analys av resultat.....	11
3.2.2. Agentbaserad simulering och visualisering.....	13
3.3. Analys och jämförelse av modellerna.....	16
3.3.1. Deterministiskt vs. Stokastisk dynamik.....	16
3.3.2. Geografiska faktorer och klustring.....	16
3.3.3. Modellernas praktiska användbarhet.....	16
3.4. Känslighetsanalys och parametervariation.....	17
3.5. Stokastiska effekter och slumpens betydelse i ABM.....	18
3.6. Sammanfattning av resultaten.....	18
4. Slutsatser.....	19
4.1. Programmering som verktyg för analys av smittspridning.....	19
4.2. Faktorer som påverkar smittspridningen: Smittsamhet och kontakter.....	19
4.2.1. Smittsamhet (.....)	19
4.2.2. Kontakter och rörlighet.....	19
4.3. Visualisering av resultat.....	20
4.3.1. Tidsseriediagram.....	20
4.3.2. Spatiala snapshots.....	20
4.4. Historisk användning av modeller.....	20
4.5. Sammanfattande reflektion av resultaten.....	21
5. Diskussion.....	22
5.1. Analys av modellernas resultat och smittans dynamik.....	22

5.2. Den geografiska faktorn och klustringens betydelse.....	22
5.3. Programmering som vetenskaplig metod.....	22
6. Metoddiskussion.....	23
6.1. Modellernas tillförlitlighet och validitet.....	23
6.2. Teknisk utvärdering av simuleringen.....	23
6.3. Källkritisk granskning.....	23
7. Förslag på vidare forskning.....	24
7.1. Vaccinationsstrategier.....	24
7.2. Nätverksanalys.....	25
7.3. Mutation och varianter.....	25
8. Källförteckning.....	26
9. Bilagor.....	27
9.1. Matematiska modellen källkod:.....	27
9.2. Agent-baserad modell källkod:.....	28
9.3. Versionering av kod.....	31

1. Inledning

Detta kapitel introducerar arbetets bakgrund, syfte och metod. Här presenteras även de frågeställningar som ligger till grund för undersökningen samt en översikt av hur arbetet har genomförts.

1.1. Inledning

Teknik och programmering används i allt större utsträckning inom naturvetenskap för att förstå, förklara och förutsäga komplexa fenomen. Ett exempel är hur simuleringar och modeller används för att studera smittspridning av sjukdomar. Under de senaste åren har samhället blivit allt mer medvetet om hur snabbt smittsamma sjukdomar kan spridas, som COVID-19, och hur viktigt det är att kunna analysera olika scenarier.

Jag har länge varit intresserad av programmering och vill nu undersöka hur matematiska modeller kan omsättas i kod för att analysera smittspridning. Ämnet är relevant eftersom det kopplar ihop teknik, matematiska modeller och naturvetenskap och visar hur programmering kan användas som ett verktyg för analys i verkliga situationer.

1.2. Syfte och avgränsningar

Syftet med arbetet är att analysera hur matematiska modeller, särskilt SIR-modellen, kan beskriva smittspridning och hur parametrar påverkar epidemins förlopp. Programmering används som ett verktyg för beräkning, simulering och visualisering. Arbetet avgränsas till en förenklad population, med fokus på matematiska principer och simulering, inte på biologiska detaljer på cellnivå.

1.3. Frågeställningar

För att konkretisera syftet formulerades följande frågeställning:

Hur kan en programmerad simulering användas för att visa och analysera smittspridning i en population?

Delfrågor:

- Hur påverkas smittspridningen av faktorer som smittsamhet och antal kontakter?
- Hur kan resultat från simuleringen visualiseras på ett tydligt sätt?
- Hur har simuleringar och matematiska modeller historiskt använts för att förstå sjukdomsspridning?

För att besvara dessa frågeställningar används följande metod:

1.4. Metod och material

Arbetet genomfördes som en kombination av litteraturstudie och kvantitativ simulering. Den teoretiska grunden baseras på epidemiologiska modeller, främst SIR-modellen, som sedan implementeras i Python för att möjliggöra systematiska experiment.

1.4.1. Simuleringsdesign

Två typer av modeller användes:

- En deterministisk SIR-modell baserad på differentialekvationer
- En stokastisk agentbaserad modell (ABM)

För att säkerställa jämförbarhet användes en fast populationsstorlek i respektive modell. I den matematiska modellen sattes populationen till $N = 1000$, medan den agentbaserade modellen använde $N = 300$ individer.

1.4.2. Parametervariation

För att undersöka hur olika faktorer påverkar smittspridningen varierades centrala parametrar systematiskt:

- Smittsamhet (β): testades med värdena 0.2 och 0.5
- Tillfriskningshastighet (γ): hölls konstant vid 0.1
- Rörlighet (speed) i ABM: varierades mellan 0.003 och 0.009
- Infektionsradie (infection radius): varierades mellan 0.015 och 0.035

1.4.3. Upprepade simuleringar (stokastisk modell)

Eftersom den agentbaserade modellen innehåller slumpmässiga element genomfördes flera simuleringar med olika startvärden för slumpgeneratoren (`np.random.seed`). Detta gjordes för att undersöka variationen i resultaten och minska risken för att enskilda körningar påverkar slutsatserna.

Resultaten analyserades både enskilt och genom att identifiera återkommande mönster mellan simuleringarna.

1.4.4. Datainsamling

Följande variabler registrerades under simuleringarna:

- Antal mottagliga (S), smittade (I) och återhämtade (R) över tid
- Tidpunkt för maximal smittspridning (peak infection)
- Maximalt antal smittade individer
- Epidemins totala varaktighet

Dessa data lagrades i arrayer och visualiserades med hjälp av Python-biblioteket Matplotlib.

1.4.5. Analysmetod

Analysen genomfördes genom att:

- Jämföra tidsserier mellan olika parametrar
- Identifiera skillnader i toppvärden och spridningshastighet
- Studera geografiska mönster och klustring i den agentbaserade modellen.

Mycket vikt lades vid att analysera hur förändringar i smittsamhet och rörlighet påverkar reproduktionstalet och därmed epidemins utveckling.

1.4.6. Begränsningar

Modellerna bygger på förenklade antaganden, såsom en homogen population (i SIR-modellen) och identiska agenter (i ABM). Resultaten bör därför tolkas som principiella snarare än exakta förutsägelser av verkliga epidemier.

1.5. Arbetsplan

Arbetet har genomförts stegvis enligt en planerad tidsstruktur. Inledningsvis fokuserade jag på att sätta mig in i den teoretiska bakgrunden till smittspridning och epidemiologiska modeller. Detta inkluderade studier av SIR-modellen samt historiska och moderna exempel på hur simuleringar används inom forskning.

Därefter planerades programmets struktur, följt av implementeringen av simuleringarna i Python. Under denna fas utvecklas både en matematisk modell och en agentbaserad modell, vilket möjliggjorde en jämförelse mellan olika angreppssätt (se källkod i bilagor).

I nästa steg testades simuleringarna genom att variera olika parametrar, såsom smittsamhet och rörlighet. Resultaten samlades in och analyserades för att identifiera mönster och samband.

Avslutningsvis sammanställdes arbetet i en rapport där både teori, metod och resultat presenterades. Parallellt förbättrades kodens struktur och visualiseringarna för att tydligare kunna kommunicera resultaten.

Arbetet byggde delvis på tidigare kunskaper inom programmering och problemlösning, men krävde även ny inlärning, särskilt inom epidemiologiska modeller och datavisualisering. En förväntad utmaning var att balansera modellens enkelhet med dess realism, samt att tolka resultaten på ett vetenskapligt sätt.

Tidsplanen följdes mest, men vissa moment, särskilt analys och visualisering, krävde mer tid än förväntat.

2. Bakgrund

Detta kapitel ger en teoretisk bakgrund till ämnet smittspridning och hur den har studerats över tid. Fokus ligger på utvecklingen av epidemiologiska modeller samt hur programmering och simuleringar används för att analysera komplexa system.

2.1. Historisk utveckling av kunskap och smittspridning

Smittsamma sjukdomar har påverkat mänskligheten under lång tid. Under medeltiden saknade man vetenskapliga förklaringar till varför sjukdomar spreds. Man trodde ofta att sjukdomar berodde på dålig luft eller övernaturliga krafter.

På 1800-talet förändrades förståelse med bakterieteorin, som visade att det var mikroorganismer som orsakade sjukdomar. Forskarna Louis Pasteur och Robert Koch lade grunden för modern epidemiologi genom vaccinationer, hygienrutiner och medicinska behandlingar. Detta gjorde det möjligt att förebygga och kontrollera epidemier.

Under 1900-talet utvecklades matematiska modeller som ett sätt att analysera sjukdomars spridning i populationer. SIR-modellen, som skapades på 1920-talet av William Ogilvy Kermack och Anderson Gray McKendrick, blev en grundläggande modell för att beskriva hur epidemier beter sig. Modellen delar upp populationen i tre grupper:

I SIR-modellen delas befolkningen in i tre grupper:

- Susceptible (S) - personer som kan bli smittade.
- Infected (I) - personer som är smittade och kan sprida sjukdomen.
- Recovered (R) - personer som har tillfrisknat och fått immunitet.



Bild 1: SIR-modellens faser.

Modellen bygger på matematiska ekvationer som beskriver hur individer övergår mellan dessa grupper. Smittspridningen påverkas av faktorer som smittsamhet, kontakt mellan människor och hur länge en person är sjuk. Genom att ändra dessa parametrar kan forskare undersöka hur epidemier utvecklas under olika förhållanden.

Ett centralt begrepp i modeller för smittspridning är reproduktionstalet, ofta kallat R_0 . Det beskriver hur många personer en smittad individ i genomsnitt smittar i en mottaglig population. Om R_0 är större än 1 kan sjukdomen spridas, medan ett värde under 1 innebär att epidemin avtar.

2.2. Datorbaserade simuleringar inom epidemiologi

Under senare delen av 1900-talet och början av 2000-talet har datorn fått en allt större betydelse inom epidemiologi. Med hjälp av programmering kan forskare skapa simuleringar som visar hur sjukdomar sprids i komplexa system. Dessa modeller kan ta hänsyn till fler faktorer än traditionella matematiska modeller, exempelvis sociala nätverk, resor och olika beteenden.

Simuleringar används för att testa olika scenarier, till exempel hur vaccination, isolering eller minskade kontakter påverkar smittspridningen. Eftersom det är svårt och oetiskt att experimentera med verkliga epidemier är simuleringar ett viktigt verktyg för forskning och beslutsfattande.

Ett aktuellt exempel är pandemin med COVID-19, som orsakades av viruset SARS-CoV-2. Under denna period användes modeller och simuleringar för att förutsäga smittspridning och planera åtgärder. Myndigheter och forskare använde modeller för att uppskatta belastning på sjukvården och utvärdera strategier som vaccination och social distansering.

2.3. Visualisering och programmering

Visualisering är en central del av simuleringar. Genom diagram, grafer och animationer kan man tydligt visa hur en epidemi utvecklas över tid. Exempelvis kan man se när antalet smittade når sin topp och hur snabbt smittan sprids. Visualisering gör det lättare att tolka resultaten och kommunicera dem till både forskare och beslutsfattare.

Programmering har därför blivit ett viktigt verktyg inom naturvetenskap. Genom att kombinera matematiska modeller med programmering kan man skapa simuleringar som hjälper till att förstå komplexa situationer. Inom utbildning används sådana modeller för att visa hur teori och praktik hänger ihop.

Över tiden har kunskapen om smittspridning utvecklats från enkla observationer till avancerade matematiska och datorbaserade modeller. Idag används simuleringar inom forskning, samhällsplanering och utbildning. Denna utveckling visar hur programmering kan fungera som ett viktigt verktyg för att analysera och förstå smittspridning.

3. Undersökning

I detta kapitel genomförs den praktiska undersökningen. Här presenteras de matematiska modellerna, deras implementering i programmering samt resultaten från simuleringarna. Kapitlet innehåller även analyser och jämförelser mellan olika modeller.

3.1. Matematiska grunder: SIR-modellen

För att kunna simulera smittspridning används den så kallade SIR-modellen, som är en matematisk modell där populationen delas in i tre grupper: mottagliga (Susceptible), smittade (Infected) och återhämtade (Recovered).

Modellen beskrivs med följande differentialekvationer:

$$\frac{dS}{dt} = -\beta SI$$

$$\frac{dI}{dt} = \beta SI - \gamma I$$

$$\frac{dR}{dt} = \gamma I$$

Här representerar S (susceptible) de mottagliga, I (Infected) de smittade och R (Recovered) de som tillfrisknat med immunitet. Parametern β (beta) definierar smittsamheten per kontakt och tidsenhet, medan γ (gamma) är den hastighet med vilken individer tillfrisknar.

$\frac{1}{\gamma}$ ger den genomsnittliga sjukdomstiden. Produkten av SI visar att smittspridning beror på möten mellan mottagliga och smittade individer.

I den praktiska implementationen av den agentbaserade modellen (se Bilaga) motsvaras den matematiska parametern γ av variabeln `recovery\_steps`. Sambandet definieras som

$$\gamma = \frac{1}{\text{recovery_steps}}$$

Detta innebär att om en agent är sjuk i till exempel 80 tidssteg (`recovery\_steps = 80`), blir tillfriskningshastigheten $\gamma = 1/80 \approx 0.0125$ per tidssteg.

Genom att definiera sjukdomstiden i antal steg blir koden mer intuitiv att läsa och håller samtidigt den matematiska strukturen

En viktig insikt i modellen är det *fundamentala reproduktionstalet*: $R_0 = \frac{\beta}{\gamma}$

Om $R_0 > 1$ kommer antalet smittade att öka exponentiellt initialt, vilket skapar en epidemi. Om $R_0 < 1$ avtar epidemin. Genom att implementera dessa ekvationer i Python kan vi simulera hur förändringar i mänskligt beteende eller virusets egenskaper påverkar hela populationen på ett deterministiskt sätt.

3.2. Implementation av två modeller och parameteranalys

Med den teoretiska grunden etablerad övergår arbetet till den praktiska implementationen av modellerna.

3.2.1. Matematisk modell och analys av resultat

För att besvara hur faktorer som smittsamhet och kontakter påverkar förloppet, genomfördes två simuleringar med den matematiska modellen där variabeln för smittsamhet (β) förändrades två gånger.




Bild 2: Simulering med beta 0.2 och gamma 0.1




Bild 3: Simulering med beta 0.5 och gamma 0.1

Vid jämförelse av Bild 2 och Bild 3 framgår det tydligt att smittsamheten är den enskilt viktigaste faktorn för epidemins toppvärde. I Bild 2 ($R_0 = 2$) ser vi en plattare kurva där sjukvården skulle ha betydligt bättre förutsättningar att hantera belastningen. I Bild 3 ($R_0 = 5$) komprimeras hela förloppet. Smittspridningen sker explosivt och når en betydligt högre topp på kortare tid. Detta besvarar delfrågan om hur faktorer som smittsamhet påverkar förloppet.

En högre smittsamhet leder till att fler blir sjuka och att samhällets resurser belastas mer intensivt under en kortare period. Utöver toppvärdet påverkar smittsamheten även hur stor del av den totala befolkningen som hinner smittas innan utbrottet klingar av. Genom att sänka β ytterligare kan man observera fenomenet där epidemin dör ut trots att en stor del av populationen aldrig har varit infekterad.




Bild 4: Simulering av flockimmunitet med parametrarna $N = 1000$, $\beta = 0.15$ och $\gamma = 0.1$. Här illustreras hur epidemin avstannar trots att ca 40 % av populationen fortfarande är mottaglig (S), då det låga reproduktionstalet gör att smittkedjan bryts i förtid.

Denna typ av programmerad simulering är viktig eftersom den gör det möjligt att isolera enskilda variabler. Något som är praktiskt taget omöjligt i verkliga observationer. Genom att visualisera dessa data i form av tidsserier kan man snabbt identifiera när en epidemi kulminerar och hur lång tid det tar innan flockimmunitet uppnås.

3.2.2. Agentbaserad simulering och visualisering

Medan den matematiska SIR-modellen ger en makroskopisk överblick, krävs en agentbaserad modell (ABM) för att analysera smittspridningens geografi och stokastiska (slumpmässiga) natur. I denna simulering interagerar 300 unika agenter som rör sig på ett tvådimensionellt plan. Inspiration till denna metodik och dess visualisering har hämtats från 3Blue1Brown (2020), som demonstrerade hur rörelsemönster och fysisk närhet är avgörande för att förstå epidemiers dynamik bortom de förenklade differentialekvationerna.

3.2.2.1. Modellens parametrar och miljö

För att konkretisera analysen definieras ett tidssteg i modellen som en dag. En simulering över 400 steg motsvarar således drygt ett år. I koden motsvaras den matematiska parametern γ av variabeln `recovery_steps`. Sambandet definieras som:

$$\gamma = \frac{1}{\text{recovery_steps}}$$

Detta innebär att om en agent är sjuk i 14 dagar (`recovery_steps = 14`), blir tillfriskningshastigheten $\gamma \approx 0,07$ per dag, vilket är en rimlig approximation för många virussjukdomar.

Simuleringsytan är modellerad som en så kallad torus-värld. I koden implementeras detta genom modulo-operatorn (`% 1.0`) på agenternas positioner. Det innebär att världen saknar hårda gränser; en agent som lämnar den högra kanten träder omedelbart in från den vänstra. Detta förhindrar att agenter artificiellt klumpas ihop mot väggar och säkerställer en homogen populationstäthet, vilket skapar en mer stabil miljö för att studera smittspridningens rena dynamik.



Bild 5: Simulering med $speed = 0.009$, $infection\ radius = 0.035$ och $infection\ probability = 0.35$

Bild 5 illustrerar hur smittan sprids genom lokala interaktioner med hög rörlighet ($speed = 0.009$). Till skillnad från den matematiska modellens jämna kurvor visar snapshots i t-stegen hur smittan bildar fysiska kluster. Detta ger en mer realistisk bild av verkliga utbrott, där smittan ofta etableras i lokala grupper innan den sprids vidare till nya områden genom möten mellan individer.



Bild 6: Simulering med $speed = 0.003$, $infection\ radius = 0.015$ och $infection\ probability = 0.35$

I Bild 6 sänks parametrarna för rörlighet ($speed$) och kontaktradi (infection_radius). Resultatet är mycket annorlunda: genom att simulera vad som i praktiken motsvarar social distansering och isolering, ser man att epidemin aldrig lyckas få ett fäste i hela populationen.

Där Bild 5 visar en snabb spridning över hela ytan, visar Bild 6 hur de infekterade (röda prickarna) förblir isolerade i små, kortvariga kluster. Eftersom agenterna rör sig långsammare hinner de ofta tillfriskna (Recovered) innan de kommer i kontakt med en tillräckligt stor mängd mottagliga individer för att upprätthålla smittkedjan. Detta sänker det effektiva reproduktionstalet (R_e) till under 1, vilket resulterar i en "utplanad kurva" (flattening the curve). Visualiseringen gör det här tydligt genom att transformera abstrakta sannolikheter till en konkret bild av hur minskad rörlighet räddar liv genom att begränsa virusets räckvidd.

Visualiseringen i den agentbaserade modellen fyller en viktig funktion för att kommunicera komplex data. Genom att använda olika färger för olika tillstånd transformeras matematiska sannolikheter till en begriplig visuell representation av social distansering. Om parametern speed eller infection radius sänks, kan man direkt se hur de röda prickarna isoleras, vilket gör det lättare att tolka resultatet än att bara studera rådata i en tabell.

3.3. Analys och jämförelse av modellerna

Efter att modellerna har implementerats och testats följer en analys och jämförelse av deras egenskaper.

3.3.1. Deterministiskt vs. Stokastisk dynamik

Den största skillnaden mellan den matematiska SIR-modellen och den agentbaserade modellen (ABM) är hur slumpen hanteras. SIR-modellen är deterministisk. Med samma startvärde ger den exakt samma resultat varje gång. Den utgår från "massverkan", det vill säga att alla individer har lika stor chans att träffa alla andra. ABM-modellen är däremot stokastisk (slumpmässig). Trots samma parametrar kommer varje körning se olika ut eftersom agenternas rörelser och smittotillfällen styrs av sannolikheter. Detta speglar verkligheten bättre, där en "superspridare" eller en isolerad grupp kan avgöra om ett utbrott dör ut eller blir en pandemi.

3.3.2. Geografiska faktorer och klustring

I den matematiska modellen sprids smittan jämnt i hela populationen samtidigt. I ABM-modellen ses tydlig klustring. Smittan sprids fysiskt från individ till individ, vilket skapar lokala härdar. Detta gör att man kan studera effekten av fysisk närhet på ett sätt som differentialekvationerna inte tillåter. ABM visar att smittspridning inte bara handlar om hur många man träffar, utan vilka man träffar och hur man rör sig i rummet.

3.3.3. Modellernas praktiska användbarhet

SIR-modellen är överlägsen för att snabbt beräkna teoretiska slutpunkter och förstå det grundläggande reproduktionstalet (R_0). Den kräver lite datorkraft och ger tydliga svar. ABM-modellen är däremot mer kraftfull för att utvärdera specifika interventioner, som till exempel vad som händer om en viss procent av befolkningen stannar hemma. Jämförelsen visar att programmering gör det möjligt att gå från abstrakta ekvationer till en visuell och experimentell miljö där komplexa beteenden kan observeras.

3.4. Känslighetsanalys och parametervariation

För att förstå hur robusta modellerna är och hur känsliga de är för förändringar, utfördes en känslighetsanalys där parametrarna β (smittsamhet) och γ (tillfrisknings-hastighet) varierades systematiskt. Genom att manipulera β i den matematiska modellen går det att identifiera den kritiska punkten där flockimmunitet uppnås. Rent matematiskt sker detta när andelen mottagliga individer S understiger kvoten γ/β . I simuleringen visualiseras detta genom att kurvan för de smittade (I) börjar plana ut långt innan hela populationen har kommit i kontakt med smittan. En central insikt från denna analys är att även om det totala antalet individer som förr eller senare blir sjuka kan vara detsamma i två olika scenarier, kan själva hastigheten, alltså lutningen på kurvan, skilja sig drastiskt. Detta är kritiskt för samhällsplanering och sjukvårdens belastning, vilket i koden direkt motsvaras av derivatan dI/dt .




Bild 7: Känslighetsanalys av den deterministiska SIR-modellen. Diagrammet illustrerar hur variationer i smittsamhet (β) påverkar epidemins intensitet och tidpunkt för toppnotering. En högre smittsamhet resulterar i en brantare kurva och en tidigare belastningstopp för systemet.

3.5. Stokastiska effekter och slumpens betydelse i ABM

I den agentbaserade modellen (ABM) introduceras slumpmässiga element som inte existerar i den deterministiska SIR-modellen, vilket ger en mer nyanserad bild av verkliga utbrott. En särskilt intressant observation vid körning av simuleringen är hur sårbar en epidemi är i sitt absoluta initialske. Vid tidpunkter nära $t = 0$ finns en påtaglig risk för så kallad stokastisk utsläckning; om de första infekterade agenterna av ren slump rör sig bort från andra mottagliga agenter, kan smittan dö ut trots att det teoretiska reproduktionstalet R_0 är högt. Detta är ett fenomen som den matematiska modellen helt missar, då den utgår från en perfekt blandad population där smittan alltid sprids så länge de matematiska förutsättningarna är uppfyllda. Genom att experimentera med olika startvärden för slumpgeneratorn (`np.random.seed`) i Python-koden, kunde det observeras hur identiska parametrar ledde till vitt skilda geografiska spridningsmönster och klusterbildningar, vilket understryker betydelsen av individnivåns rörelsemönster.




Bild 8: Jämförelse av tre oberoende körningar av den agentbaserade modellen med identiska startparametrar. Skillnaderna i kurvornas förlopp demonstrerar slumpens betydelse (stokastik) i små populationer, där individuella rörelsemönster kan avgöra om ett utbrott tar fart eller dör ut tidigt.

3.6. Sammanfattning av resultaten

Resultaten visar att smittsamheten är den mest avgörande faktorn för epidemins intensitet, medan rörlighet och kontakt radie i den agentbaserade modellen styr hur snabbt och geografiskt smittan sprids. Den deterministiska modellen ger en tydlig överblick av förloppet, medan den agentbaserade modellen kompletterar med insikter om klustring och slumpens betydelse.

Modellerna kan sägas besvara olika typer av frågor: SIR-modellen beskriver hur mycket smitta som sprids över tid, medan den agentbaserade modellen visar hur smittan sprids i rummet. Kombinationen av dessa perspektiv ger en mer komplett förståelse av epidemins dynamik.

4. Slutsatser

Resultaten i denna studie visar att programmerade simuleringar är ett effektivt verktyg för att analysera smittspridning i en population. Genom att kombinera matematiska modeller med programmering har det varit möjligt att undersöka hur olika parametrar påverkar epidemins förlopp och därmed besvara arbetets frågeställningar.

4.1. Programmering som verktyg för analys av smittspridning

Huvudfrågan i detta arbete fokuserade på hur en programmerad simulering kan användas för att analysera smittspridning i en population. Undersökningen visar att programmering fungerar som en brygga mellan statisk matematisk teori och dynamisk verklighet. Genom att använda Python-kod har arbetet visat att man kan skapa en kontrollerad miljö där komplexa biologiska skeenden förenklas till matematiska regler. Genomförandet av simuleringarna visade att programmering tillåter oss att isolera variabler på ett sätt som är omöjligt i verkligheten. Genom att köra koden upprepade gånger med små förändringar i parametrarna har det kunnat fastställas att programmering inte bara bekräftar matematiska modeller (som SIR), utan även gör dem praktiskt användbara för att förutsäga tidpunkten för en epidemins kulminering och dess totala omfattning.

4.2. Faktorer som påverkar smittspridningen: Smittsamhet och kontakter

Delfrågan angående hur faktorer som smittsamhet och antal kontakter påverkar förloppet har besvarats genom jämförande analyser i både den matematiska och den agentbaserade modellen.

4.2.1. Smittsamhet (β)

Resultaten från den matematiska modellen visar att smittsamheten är den mest kritiska faktorn för hur intensiv en epidemi blir. En ökning av β från 0.2 till 0.5 resulterade i en dramatiskt högre och tidigare smitt-topp. Detta bekräftar att virusets inneboende egenskaper direkt dikterar belastningen på samhällets resurser.

4.2.2. Kontakter och rörlighet

Genom den agentbaserade modellen har det kunnat visas att smittspridningen är direkt beroende av individers rörlighet (speed) och det fysiska avståndet (infection_radius). När rörligheten minskades i simuleringen, sjönk det effektiva reproduktionstalet (R_e).

Slutsatsen är att även om ett virus är mycket smittsamt, kan spridningen effektivt strypas genom att begränsa antalet möten mellan infekterade och mottagliga individer. Detta visar att "social distansering" som parameter i koden ger ett direkt utslag i en utplattad smittkurva.

4.3. Visualisering av resultat

Frågeställningen om hur resultat kan visualiseras på ett tydligt sätt har besvarats genom användandet av olika grafiska metoder i Python-biblioteket Matplotlib. Undersökningen visar att två typer av visualiseringar kompletterar varandra:

4.3.1. Tidsseriediagram

Tidsserier från SIR-modellen gör det möjligt att tydligt se hur populationen förändras över tid. De visar:

- när epidemin startar
- när den når sin topp
- hur den avtar

Detta ger en tydlig makroskopisk bild av förloppet.

4.3.2. Spatiala snapshots

Den agentbaserade modellen visualiserar smittan som fysiska kluster. Genom att använda färgkodning (blått för friska, rött för smittade, grönt för immuna) transformeras abstrakta siffror till en visuell representation av hur sjukdomen rör sig genom ett rum.

Slutsatsen är att visualisering är nödvändig för att göra data begriplig för icke-matematiker och för att snabbt kunna kommunicera risker och effekter av olika åtgärder.

4.4. Historisk användning av modeller

Den sista delfrågan rörande hur simuleringar och modeller historiskt har använts visar på en tydlig utvecklingslinje från manuell matematik till datoriserad epidemiologi.

Litteraturstudien visar att SIR-modellen, som skapades av Kermack och McKendrick på 1920-talet, lade den teoretiska grunden genom att dela upp befolkningen i fack (compartments).

Slutsatsen av den historiska genomgången är att vi i dag använder precis samma matematiska logik som för hundra år sedan, men att vi med hjälp av programmering nu kan lägga till komplexitet såsom slump (stokastik) och geografiska faktorer.

Under COVID-19-pandemin, som nämns i bakgrunden, var dessa modeller fundamentala för att myndigheter skulle kunna planera för sjukhuskapaciteten, vilket visar på modellernas fortsatta relevans och livsviktiga funktion i det moderna samhället.

4.5. Sammanfattande reflektion av resultaten

Summerat visar undersökningen att smittspridning inte är en slumpmässig process utan följer tydliga matematiska mönster som kan fångas i kod. Genom att manipulera parametrar för smittsamhet och rörlighet i simuleringarna har arbetet visat hur man kan "platta till kurvan".

Arbetet har därmed uppfyllt sitt syfte att visa hur teknik och matematik samverkar för att ge oss verktyg att förstå och bekämpa globala hälsoutmaningar.

Parameter	Förändring	Effekt på pandemin	Konsekvens i simuleringen
Smittsamhet (β)	Ökning	Högre och tidigare smittstopp	Kurvan komprimeras och blir brantare
Tillfrisknande (γ)	Ökning	Kortare sjukdomstid	Lägre totalt antal smittade och lägre R_0
Rörlighet (speed)	Minskning	Långsammare spridning	"Flattening the curve" (utplanad kurva)
Infektionsradie	Minskning	Färre lokala kontakter	Smittkedjor bryts och kluster isoleras
Vaccinationsgrad (R_{start})	Ökning	Snabbare flockimmunitet	Epidemin når aldrig en kritisk massa

5. Diskussion

I detta kapitel diskuteras resultaten ur ett bredare perspektiv. Här analyseras deras betydelse, begränsningar samt kopplingen till verkliga situationer och tidigare forskning.

Resultaten från simuleringarna har tydliga paralleller till verkliga epidemier. Särskilt framträder hur små förändringar i beteende, såsom minskad rörlighet eller färre kontakter, kan få stora effekter på smittspridningens utveckling. Detta bekräftar varför åtgärder som social distansering och restriktioner införs tidigt i en epidemi, då de kan sänka det effektiva reproduktionstalet och därmed begränsa spridningen.

5.1. Analys av modellernas resultat och smittans dynamik

Resultaten från både den matematiska SIR-modellen och den agentbaserade simuleringen visar att smittspridning inte är en linjär process, utan styrs av kritiska tröskelvärden. Den mest centrala insikten är hur känsligt systemet är för parametern β . I simuleringen ser vi att en relativt liten ökning av smittsamheten inte bara leder till fler sjuka, utan till en exponentiell acceleration som snabbt mättar systemet.

Detta bekräftar varför begreppet "flattening the curve" är så fundamentalt; det handlar om att genom små ingrepp i smittsamhet eller rörlighet förskjuta toppen i tid och sänka dess amplitud, vilket i förlängningen räddar liv genom att avlasta sjukvården.

5.2. Den geografiska faktorn och klustringens betydelse

Genom att använda programmering som verktyg har jag kunnat belysa det som de rena differentialekvationerna ofta missar: geografins betydelse. I den agentbaserade modellen framgår det tydligt att smittan sprids via fysiska kluster. Till skillnad från SIR-modellens antagande om en perfekt blandad befolkning ("mass action"), visar mina resultat att smittan i en fysisk miljö är beroende av lokala interaktioner. Om rörligheten (speed) sänks, isoleras dessa kluster och epidemin dör ut lokalt innan den hinner bli en pandemi. Detta ger ett vetenskapligt stöd för restriktioner som fokuserar på att begränsa rörlighet snarare än att bara behandla de som redan är sjuka.

5.3. Programmering som vetenskaplig metod

Att omsätta matematik till kod har i detta arbete fungerat som en brygga mellan teori och visuell verklighet. Det som ekvationerna beskriver som en hastighetsförändring i en grupp, visar simuleringen som en enskild individs rörelse. Detta visar på programmeringens styrka inom naturvetenskapen; vi kan skapa kontrollerade "laboratoriemiljöer" i datorn för att testa scenarier som vore oetiska eller praktiskt omöjliga att utföra i verkligheten. Att de modeller som skapades på 1920-talet fortfarande är relevanta i dagens datoriserade samhälle tyder på att de lyckades fånga en universell sanning om mänskligt samspel.

6. Metoddiskussion

Detta kapitel fokuserar på de metoder som använts i arbetet. Här diskuteras styrkor och svagheter i tillvägagångssättet, samt hur dessa kan ha påverkat resultatens tillförlitlighet.

6.1. Modellernas tillförlitlighet och validitet

Kombinationen av en deterministisk och en stokastisk modell har gett arbetet en bredd som en enskild metod hade saknat. SIR-modellen ger en exakt och repeterbar sanning, medan den agentbaserade modellen introducerar den slump som alltid finns i biologiska system.

En kritisk punkt är dock populationsstorleken. Med endast 300 agenter blir de stokastiska effekterna mycket framträdande. Vid flera testkörningar dog epidemin ut tidigt av ren slump (stokastisk utsläckning), vilket är en felkälla som i en professionell studie borde hanteras genom att köra simuleringen tusentals gånger för att få fram ett statistiskt medelvärde.

En metodologisk begränsning är att SIR-modellen antar en homogen blandning av populationen, vilket innebär att alla individer har lika stor sannolikhet att mötas. Detta leder till en överskattning av smittspridningens hastighet jämfört med verkliga samhällen där kontakter är strukturerade. Den agentbaserade modellen hanterar detta bättre genom att inkludera rumsliga interaktioner, men introducerar istället slumpmässiga variationer som kan ge stora utslag i små populationer. Detta innebär att modellen har högre realism men lägre reproducerbarhet.

6.2. Teknisk utvärdering av simuleringen

Valet av en "torus-värld" i koden är en teknisk förenkling för att undvika kanteffekter där agenter fastnar. Även om detta är elegant rent programmeringsmässigt, är det en begränsning för modellens validitet i förhållande till verkligheten. Riktiga miljöer har barriärer, flaskhalsar och sociala strukturer som hem och arbetsplatser. Dessutom antar modellen att alla agenter är identiska, vilket ignorerar att vissa individer fungerar som "superspridare" på grund av ett större kontaktnät. Trots dessa förenklingar anser jag att metoden är robust nog för att dra principiella slutsatser om hur parametrar som smittsamhet och rörlighet samverkar.

6.3. Källkritisk granskning

De källor som använts, främst ETH Zürich och vetenskapliga artiklar från Science, håller en hög akademisk standard och är verifierbara. Historiken kring SIR-modellen är väl dokumenterad, vilket gör att basen för arbetet vilar på beprövad vetenskap. Wikipedia och YouTube (3Blue1Brown) har fungerat som pedagogiska ingångar för att förstå den bakomliggande koden, men har konsekvent kontrollerats mot de primära matematiska källorna för att säkerställa att ingen misinformation har smugit sig in i arbetet.

En ytterligare aspekt rör studiens validitet och reliabilitet. Den deterministiska modellen har hög reliabilitet eftersom den ger samma resultat vid varje körning, medan den agentbaserade modellen har lägre reliabilitet på grund av slumpmässiga variationer. Samtidigt har den högre ekologisk validitet eftersom den bättre efterliknar verkliga spridningsmönster. Kombinationen av dessa modeller stärker därmed arbetets totala trovärdighet.

7. Förslag på vidare forskning

Detta kapitel presenterar möjliga utvecklingsområden baserade på arbetets resultat. Här ges förslag på hur modellerna kan förbättras och vilka aspekter som kan undersökas vidare.

7.1. Vaccinationsstrategier

En naturlig vidareutveckling av modellerna är att inkludera vaccination som en parameter. Detta skulle kunna implementeras genom att en viss andel av populationen initialt placeras i gruppen "Recovered", eller genom att införa en dynamisk vaccinationsprocess över tid.

Genom att simulera olika vaccinationsnivåer och strategier, exempelvis slumpmässig vaccination eller riktad vaccination mot individer med många kontakter, kan man analysera hur flockimmunitet uppnås och hur epidemins förlopp påverkas. Detta skulle ge en mer direkt koppling till verkliga folkhälsostراتيجier.

Som en förlängning av analysen kring social distansering kan modellen användas för att simulera proaktiva åtgärder som vaccination. Genom att introducera agenter som startar i tillståndet Recovered (R) skapas "sköldar" i populationen.




Bild 9: Simulering av vaccinationsgrad. Genom att initialt vaccinera 40 % av populationen ($R_{start} = 120$) bryts smittkedjorna effektivt, vilket resulterar i att epidemin aldrig når en kritisk massa trots hög rörlighet bland resterande agenter.

7.2. Nätverksanalys

I den nuvarande modellen antas att alla individer rör sig slumpmässigt i ett kontinuerligt rum. En mer realistisk modell skulle istället kunna baseras på sociala nätverk, där individer endast interagerar med specifika kontakter.

Genom att använda nätverksmodeller, exempelvis grafstrukturer där noder representerar individer och länkar representerar kontakter, kan man studera hur smittspridning påverkas av nätverkets struktur. Detta möjliggör analys av fenomen som "superspridare" och hur vissa individer har en oproportionerligt stor påverkan på epidemins utveckling.

7.3. Mutation och varianter

En ytterligare utveckling är att inkludera mutationer av viruset i modellen. Detta kan implementeras genom att introducera flera varianter med olika smittsamhet (β) och tillfriskningshastighet (γ).

Genom att simulera konkurrens mellan olika varianter kan man analysera hur mer smittsamma mutationer tar över i populationen. Detta är särskilt relevant i verkliga pandemier, där nya varianter kan förändra smittspridningens dynamik och påverka effektiviteten av tidigare immunitet eller vaccination.

8. Källförteckning

Följande källor har använts i arbetet och redovisas enligt vedertagen akademisk standard.

3Blue1Brown (2020). Simulating an epidemic. [Video]. YouTube:
<https://www.youtube.com/watch?v=gxAaO2rsdIs> (Hämtad 2026-03-25).

Earn, D. J. D., Rohani, P., Bolker, B. M. & Grenfell, B. T. (2000). A simple model for complex dynamical transitions in epidemics. *Science*, 287(5453), ss. 667-670.

ETH Zurich (2024). SIR models of epidemics – modeling course. [Webb].
<https://tb.ethz.ch/education/learningmaterials/modelingcourse/level-1-modules/SIR.html> (Hämtad 2026-03-28).

Kermack, W. O. & McKendrick, A. G. (1927). A Contribution to the Mathematical Theory of Epidemics. *Proceedings of the Royal Society of London. Series A*, 115(772), ss. 700-721.

University of St Andrews. Contributions to the Mathematical Theory of Epidemics. Mathshistory.
[Webb]. https://mathshistory.st-andrews.ac.uk/Extras/Epidemic_theory/ (Hämtad 2026-03-30).

Wikipedia. Compartmental models in epidemiology. [Webb].
https://en.wikipedia.org/wiki/Compartmental_models_in_epidemiology (Hämtad 2026-03-20).

9. Bilagor

9.1. Matematiska modellen källkod:

```
import numpy as np
from scipy.integrate import odeint
import matplotlib.pyplot as plt

N = 1000
I0 = 1
R0 = 0
S0 = N - I0 - R0
beta = 0.3
gamma = 0.1
t = np.linspace(0, 160, 160)

def deriv(y, t, N, beta, gamma):
    S, I, R = y
    dSdt = -beta * S * I / N
    dIdt = beta * S * I / N - gamma * I
    dRdt = gamma * I
    return dSdt, dIdt, dRdt

y0 = S0, I0, R0
ret = odeint(deriv, y0, t, args=(N, beta, gamma))
S, I, R = ret.T

plt.plot(t, S, label='Susceptible')
plt.plot(t, I, label='Infected')
plt.plot(t, R, label='Recovered')
plt.legend()

plt.savefig("SIR.png", dpi=150, bbox_inches="tight")
```

9.2. Agent-baserad modell källkod:

```
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.gridspec as gridspec
from matplotlib.lines import Line2D

np.random.seed(42)

N = 300
INITIAL_INFECTED = 3
infection_radius = 0.035
infection_prob = 0.35
recovery_steps = 80
steps = 400
speed = 0.009

S, I, R = 0, 1, 2
CLR = {S: '#4FC3F7', I: '#EF5350', R: '#66BB6A'}
LABELS = {S: 'Susceptible', I: 'Infected', R: 'Recovered'}
BG = '#0D1117'

positions = np.random.rand(N, 2)
states = np.full(N, S, dtype=int)
infected_timer = np.zeros(N, dtype=int)

recovery_time = (recovery_steps * np.random.uniform(0.7, 1.3, N)).astype(int)

seed = np.random.choice(N, INITIAL_INFECTED, replace=False)
states[seed] = I

angles = np.random.uniform(0, 2 * np.pi, (steps, N))
dx = np.cos(angles) * speed
dy = np.sin(angles) * speed

hist = {S: [], I: [], R: []}

snap_times = [0, steps // 4, steps // 2, 3 * steps // 4, steps - 1]
snapshots = {}

for t in range(steps):

    positions[:, 0] = (positions[:, 0] + dx[t]) % 1.0
    positions[:, 1] = (positions[:, 1] + dy[t]) % 1.0

    new_states = states.copy()
```

```

inf_idx = np.where(states == I)[0]
sus_idx = np.where(states == S)[0]

if len(inf_idx) > 0 and len(sus_idx) > 0:
    diff = positions[sus_idx][:, np.newaxis, :] - positions[inf_idx][np.newaxis, :, :]
    dists = np.linalg.norm(diff, axis=2)
    close = np.any(dists < infection_radius, axis=1)
    roll = np.random.rand(len(sus_idx))
    new_states[sus_idx[close & (roll < infection_prob)]] = I

inf_mask = states == I
infected_timer[inf_mask] += 1
recover_mask = inf_mask & (infected_timer >= recovery_time)
new_states[recover_mask] = R

states = new_states

for st in [S, I, R]:
    hist[st].append(int(np.sum(states == st)))

if t in snap_times:
    snapshots[t] = (positions.copy(), states.copy())

fig = plt.figure(figsize=(16, 9), facecolor=BG)
fig.suptitle('Agent-Based SIR Epidemic Simulation',
             color='#E0EEFF', fontsize=14, fontfamily='monospace', y=0.97)

gs = gridspec.GridSpec(2, 5, figure=fig,
                       left=0.04, right=0.97,
                       top=0.91, bottom=0.09,
                       wspace=0.25, hspace=0.45)

snap_labels = ['t = 0', f't = {steps//4}', f't = {steps//2}',
               f't = {3*steps//4}', f't = {steps-1}']

for col, (t, label) in enumerate(zip(snap_times, snap_labels)):
    ax = fig.add_subplot(gs[0, col], facecolor=BG)
    pos, st_arr = snapshots[t]

    for st in [S, I, R]:
        mask = st_arr == st
        ax.scatter(pos[mask, 0], pos[mask, 1],
                  c=CLR[st], s=10, alpha=0.8, linewidths=0, zorder=3)

    for v in np.linspace(0, 1, 5):
        ax.axhline(v, color='#1A2A3A', lw=0.3)

```

```

ax.axvline(v, color='#1A2A3A', lw=0.3)

ax.set_xlim(0, 1); ax.set_ylim(0, 1)
ax.set_xticks([]); ax.set_yticks([])
ax.set_title(label, color='#8899AA', fontsize=9, fontfamily='monospace', pad=4)
for spine in ax.spines.values():
    spine.set_edgecolor('#2A3A4A')

counts = {st: int(np.sum(st_arr == st)) for st in [S, I, R]}
anno = f"S:{counts[S]} I:{counts[I]} R:{counts[R]}"
ax.text(0.5, -0.06, anno, transform=ax.transAxes, ha='center',
        fontsize=7, color='#6688AA', fontfamily='monospace')

legend_elems = [Line2D([0], [0], marker='o', color='w',
                        markerfacecolor=CLR[st], markersize=7,
                        label=LABELS[st], linestyle='None')
                 for st in [S, I, R]]
fig.legend(handles=legend_elems, loc='upper center', ncol=3,
           bbox_to_anchor=(0.5, 0.535),
           framealpha=0.12, labelcolor='#CCDDEE',
           fontsize=9, edgecolor='#2A3A4A')

ax_curve = fig.add_subplot(gs[1, :], facecolor=BG)
t_arr = np.arange(steps)

bottom = np.zeros(steps)
for st in [R, I, S]:
    arr = np.array(hist[st], dtype=float)
    ax_curve.fill_between(t_arr, bottom, bottom + arr,
                          color=CLR[st], alpha=0.18, zorder=1)
    bottom += arr

for st in [S, I, R]:
    ax_curve.plot(t_arr, hist[st], color=CLR[st], lw=2,
                  label=LABELS[st], zorder=3)

peak_t = int(np.argmax(hist[I]))
peak_v = hist[I][peak_t]
ax_curve.axvline(peak_t, color='#EF5350', lw=0.8, linestyle='--', alpha=0.5)
ax_curve.scatter([peak_t], [peak_v], color='#EF5350', s=50, zorder=5)
ax_curve.text(peak_t + 4, peak_v + 4,
              f'Peak: {peak_v} infected\n@ step {peak_t}',
              color='#EF5350', fontsize=8, fontfamily='monospace')

ax_curve.set_xlim(0, steps)
ax_curve.set_ylim(0, N)
ax_curve.set_xlabel('Time step', color='#8899AA', fontsize=10)
ax_curve.set_ylabel('Individuals', color='#8899AA', fontsize=10)
ax_curve.set_title('SIR Epidemic Curve', color='#CCDDEE',
                  fontsize=11, fontfamily='monospace', pad=6)

```

```
ax_curve.grid(axis='y', color='#1A2A3A', lw=0.6)
ax_curve.tick_params(colors='#8899AA')
for spine in ax_curve.spines.values():
    spine.set_edgecolor('#2A3A4A')
ax_curve.legend(framealpha=0.15, labelcolor='#CCDDEE',
                edgecolor='#2A3A4A', fontsize=9)

plt.savefig('sir_simulation.png', dpi=150, bbox_inches='tight', facecolor=BG)
print("Saved → sir_simulation.png")
```

9.3. Versionering av kod

All kod finns också med versionerings historia på github:

<https://github.com/isak-sk/epidemic-sim>